

Ревизия исходных материалов

Приложение к ответу на тестовое задание · Plata · Group IRM · 12 августа 2026
Что найдено в приложениях A–I, тексте задания и заметках интервью

Зачем этот документ. Задание выдаёт приложения как «day-one documentation» и просит оценить ландшафт. Оценивать ландшафт, не вычитав саму документацию, нельзя: если в day-one-документе есть противоречия, то первое, с чем столкнётся новый аналитик, — именно они, а не данные. Ниже — сплошная вычитка: **20 находок**, каждая с цитатой и указанием файла и строки. Часть найдена глазами, часть — прогоном документированных запросов по воспроизведённому данным.

20

находок в исходных материалах

6

критичных: ведут к неверному числу

5

ссылок на файлы, которых нет

3

найжены только прогоном запросов

Сводка по классам

Класс	Находок	Чем опасен
A. Противоречия между документами	6	Читатель выбирает одну из двух версий и не знает, что выбрал
B. Пропуски и висячие ссылки	5	Карта схем неполна; половина отсылок ведёт в никуда
C. Примеры, работающие не как описано	4	Скопированный из документации запрос даёт неверный результат
D. Предметные ошибки	3	Календарь и справочники неверны по существу
E. Методология	2	Статистика занижает или завышает значимость

А. Противоречия между документами

№	Где	Что написано	В чём проблема	Важность
A1	Appendix B, стр. 46 / 74 / 79	«Data freshness: T-1 (calendar days)» — и в таблице ниже: «portfolio_cor ... today – 2» — и ещё ниже: «portfolio_cor is typically T-1»	Три утверждения об одной таблице, два из них несовместимы. От выбора зависит порог SLA: мониторинг на T-1 будет каждый день сигналить, мониторинг на T-2 пропустит суточную задержку	критично
A2	Appendix B против F	B: statement_id в portfolio_cor — TEXT . F: statement_id — Integer , источник ods.pf_engine.STATEMENTS	Это ключ джойна между слоями. Разные типы дают либо ошибку приведения, либо неявный каст с потерей совпадений	критично
A3	Appendix C, стр. 106 против D, стр. 62	C: SUM(cor_prnp) / SUM(avg_balance_prnp_net) * 12 , подписано «Correct COR% by vintage». D: -SUM(a.cor_prnp) / ...	В C нет минуса, а cor_prnp отрицателен по соглашению самого же Appendix C. Пример, помеченный как правильный, даёт отрицательный COR%. Там же нет фильтра по продукту, который есть в D	критично
A4	Appendix E, стр. 22 против G, стр. 55	E: формула EL LT — cor_predict_lt / bal_predict_lt . G: SUM(cor_total_predict_lt) / SUM(bal_total_predict_lt)	Колонки названы по-разному. По версии из глоссария запрос не скомпилируется	существенно
A5	Текст задания против Appendix A	Задание: «20+ schemas across 6 databases». Appendix A перечисляет девять различных префиксов баз	Расхождение в постановке. Схем в карте 19 — «20+» получается, только если добавить неуказанную ods.ref (см. B1)	незначительно
A6	Задание, Part 2 против Appendix H	В таблице трёх расчётов и Risk Analytics, и Portfolio Monitoring помечены как «Gen3», различаясь только формулой и аннуализацией	По Appendix H колонка cor в challenger-таблице исключает 0-DPD бакет , а cor_prnp в статементной — нет. Это разные числители, а не одна модель. По замерам вклад расхождения — 0.2...0.5 п.п.	существенно

В. Пропуски и висячие ссылки

№	Где	Что	В чём проблема	Важность
B1	Appendix A	Схема <code>ods.ref</code> в карте схем отсутствует (0 упоминаний), при этом в Appendix B её таблица <code>HOLIDAYS</code> документирована подробно (3 упоминания)	Карта схем, по которой ориентируются человек и агент, неполна. Причём пропущена не техническая схема, а календарь, от которого зависят все расчёты рабочих дней	критично
B2	Appendix B	<code>ods.ref.HOLIDAYS</code> документирована внутри файла «DM Schema — Table Inventory»	ODS-таблица описана в инвентаре витрины. Ищущий её по слою не найдёт	незначительно
B3	A, D, G, H	Ссылки на <code>tables_technical.md</code> , <code>tables_dm.md</code> , <code>finance/gl_tables.md</code> , <code>finance/mxgaap_provisions.md</code> , <code>risk/pilots.md</code>	Пять ссылок, ни одного файла. Приложения — выдержки из большей базы знаний, и перекрёстные ссылки при выдержке порвались. Для агента такая ссылка — тупик без сигнала об ошибке	существенно
B4	Appendix H, стр. 32	Формула <code>cor_total = cor_dlg_fact + cor_0_bucket</code> , при этом <code>cor_dlg_fact</code> и <code>cor_0_bucket</code> отсутствуют в списке ключевых колонок этой же таблицы	Формула ссылается на колонки, которых по документации не существует. Проверить аддитивность по документу нельзя	существенно
B5	Appendix H	«This decomposition avoids the known cor_collection_fact data issue »	Известный дефект данных упомянут одной фразой и нигде не описан: ни в чём он состоит, ни насколько велик, ни когда будет исправлен. Обходной путь задокументирован, причина — нет	критично

С. Примеры, работающие не как описано

Эти три находки получены не чтением, а прогоном документированных запросов по воспроизведённым данным. Глазами они не видны.

№	Где	Что заявлено	Что происходит на самом деле	Важность
C1	Appendix A и D	«Using the wrong filter column returns no results or wrong data silently »	В Snowflake обращение к несуществующей колонке даёт ошибку компиляции , а не пустой результат. Молчаливым промах бывает, только если колонка физически существует — например, осталась после переименования. Симптом описан верно, механизм — нет, и из описания непонятно, что искать	существенно
C2	Appendix C, стр. 106	Запрос подписан « - - Correct COR% by vintage »	Возвращает отрицательный процент: минус перед суммой пропущен. Аналитик, скопировавший пример, получит COR со знаком минус и либо развернёт его руками, либо построит график вверх ногами	критично
C3	Appendix B, запрос «business days in a month»	Возвращает month_start как месяц	Возвращает TIMESTAMP_NTZ , а не DATE : строковый литерал '2026-01-01' в DATEADD приводится к таймстемпу. Проверено — при джойне к результату по DATE совпадений не будет. Сам запрос отрабатывает, ошибка проявится дальше по цепочке	существенно
C4	Appendix B, стр. 77	В таблице свежести — dm_npv_gen5p_details	Такого объекта нет: везде далее dm.npv_gen5_details . Лишняя буква p плюс подчёркивание вместо точки — вероятно, след прежнего имени NPV_GEN5_PV_DETAILS , которое, по Appendix G, дропнуто	незначительно

D. Предметные ошибки

№	Где	Что написано	В чём ошибка	Важность
D1	Appendix B, стр. 97	Среди праздников: «Inauguración (Dec 1, every 6 years)»	Дата передачи исполнительной власти в Мексике перенесена с 1 декабря на 1 октября — с 2024 года. Календарь, построенный по этому описанию, поставит нерабочий день не в тот месяц раз в шесть лет и промахнётся по кварталу, на который приходится списания	существенно
D2	Appendix B, стр. 97	В том же перечне: «Día de las Madres (May 10)»	10 мая не является обязательным нерабочим днём по статье 74 федерального трудового закона и, насколько мне известно, не входит в банковский календарь CNBV. Лишний нерабочий день занижает число рабочих дней мая и искажает пересчёт COR в годовые. Требуется сверки с официальным календарём CNBV — как и весь перечень: он смешивает обязательные выходные по закону с банковскими (Semana Santa, 2 ноября, 12 декабря), не указывая, какой источник является нормативным	критично
D3	Appendix E, стр. 9	«BdC Buro de Credito Mexican credit bureau (Circulo de Credito)»	Buró de Crédito и Círculo de Crédito — два разных кредитных бюро Мексики, а не одно с двумя названиями. Строка глоссария их отождествляет. Ниже в том же файле «BDC Trans Union Califica» — ещё и разноречивой в написании аббревиатуры	существенно

E. Методология

№	Где	Что написано	В чём проблема	Важность
E1	Appendix D, t-статистика	$\text{cor\%_std} = \text{cor_forecast\%} \times \sqrt{\text{var_cor}/\text{cor}^2 + \text{var_bal}/\text{bal}^2}$, подписано «delta method for ratio variance estimation»	В дельта-методе для отношения есть третий член — ковариация числителя и знаменателя. Здесь он опущен, то есть COR и баланс считаются независимыми. Они сильно положительно связаны, поэтому дисперсия завышена, а t-статистика занижена: отклонения, которые значимы, будут выглядеть незначимыми. Допущение о независимости в тексте не заявлено	существенно
E2	Appendix D	SQL-пример считает <code>actual_cor_pct</code> и <code>forecast_cor_pct</code> положительными . Формулы Tableau рядом дают оба показателя отрицательными . Формула t использует вариант Tableau	Два соглашения о знаке в одном приложении. Подставив числа из SQL-примера в формулу t, получишь знак наоборот — то есть вывод «хуже плана» вместо «лучше плана»	критично

F. Наблюдения без статуса ошибки

- **Приоритет расставлен не по величине эффекта.** Правило «фильтруйте `statement_num >= 2`» повторено дословно **трижды** — в приложениях C, D и F. По замерам на воспроизведённых данных его вклад в

расхождение расчётов составляет 0.05–0.24 п.п., тогда как вклад выбора зерна — 2.1–2.7 п.п., то есть на порядок больше, и о нём не сказано нигде. Предупреждение верное, вес — нет.

- **Заметки интервью содержат искажения распознавания речи** и не помечены как черновик: «Axon EDC Disk Group», «diplomint coordinator», «Wisla/Voyager», «анпоинты», «lChart, ISIT». Часть периодов работы указана как «unknown». Для человека это шум, для LLM — источник, из которого он воспроизведёт несуществующие названия продуктов как факт. Такие файлы нужно либо вычитывать, либо явно помечать признаком «машинная расшифровка, не источник истины».
- **Appendix I опирается на DMBoK нестрого.** Сказано «across the 11 DMBoK disciplines», и среди шести отслеживаемых названы Change Management и Data Catalog Management. В DAMA DMBoK одиннадцать областей знаний, и таких среди них нет: каталог покрывается Metadata Management, контроль изменений — Data Governance. Reference и Master Data в DMBoK — **одна** область, здесь разделены на две. Само задание при этом просит «connect your proposals to DMBoK disciplines», поэтому терминологию стоит либо привести к рамке, либо честно назвать её собственной адаптацией.

Как это ловится системно

Главное наблюдение по итогам вычитки: **находки распадаются на классы, и каждому классу нужен свой детектор**. Один инструмент не закроет все двадцать, а попытка закрыть всё ревью «на внимательность» не масштабируется и держится на одном человеке.

Класс находок	Чем ловится	Механика	Что закрывает из списка
Документ против реальности колонки и таблицы, которых нет	dbt + линтер, детерминированно	Все имена из YAML-описаний сверяются с INFORMATION_SCHEMA ; тест падает на расхождении	A2, A4, B1, B4, C4
SQL-примеры из документации	CI, детерминированно	Каждый блок кода в документации выполняется на эталонных данных; результат сравнивается с ожидаемым. Примеры становятся тестами	C2, C3, и именно так найдены три из моих находок
Документ против документа противоречия между файлами	LLM-валидатор	Кодом ловится плохо: нужно понять, что «T-1» и «today – 2» — про одно и то же. Задача агенту ставится явно: «найди утверждения об одном объекте, которые несовместимы»	A1, A3, A5, A6, E2
Дрейф схемы	diff снимков DDL	Хеш DDL сверяется со снимком и с журналом изменений. Изменившийся хеш без записи в журнале — незарегистрированное изменение	класс C1: колонка осталась после переименования
Дрейф данных схема та же, числа другие	data diff	Построчное сравнение версий модели (audit_helper.compare_relations). Ловит пересчёт модели — тот класс, где ничего не падает	сценарий Part 3 целиком
Предметные факты календарь, справочники	сверка с внешним источником	Календарь не пишется руками, а загружается из нормативного источника (CNBV) и сверяется ежегодно	D1, D2
Методология	человек, LLM подсказывает	Агент отмечает «допущение не заявлено», решение принимает эксперт	E1

Что конкретно даёт dbt

Значительная часть того, что я собрал руками в песочнице, в продуктиве заменяется штатными механизмами dbt — и это честнее, чем поддерживать своё:

Сделано вручну	Эквивалент в dbt
26 утверждений в вью BUILD_ASSERTIONS	generic-тесты (unique , not_null , accepted_values , relationships) плюс singular-тесты для семантики: знак в агрегате, аддитивность, отсутствие выходных, нулевой COR на первом статементе
Реестр потребителей	exposures — с типом, владельцем и зависимостями; влияние изменения считается графом, а не таблицей
Комментарии к таблицам и колонкам	persist_docs — описания живут в YAML рядом с моделью и автоматически уезжают в Snowflake. Один источник вместо двух
Снимок DDL и детектор дрейфа	артефакты manifest.json + state:modified : в CI видно, что именно изменилось, ещё до применения
Каталог объектов	dbt docs — но с оговоркой: он про модели, а не про весь склад. ODS-слой всё равно нужно описывать отдельно

Чего dbt **не** закрывает: противоречий между текстовыми документами, предметных ошибок в справочниках и всего, что находится за пределами графа моделей. Именно на этот остаток и нужен агент.

Каким должен быть агент-валидатор

Ключевое требование: **валидатор — отдельная роль от аналитика**. У них разные задачи, разные права и разная цена ошибки. Аналитик отвечает на вопросы и должен быть осторожным; валидатор ищет расхождения и должен быть придирчивым.

1. **Вход:** документация, `INFORMATION_SCHEMA`, каталог, журнал изменений и результаты тестов. Не только текст — иначе сверять не с чем.
2. **Четыре явные задачи** вместо общего «проверь»: (1) выполнить все примеры кода; (2) сверить каждый упомянутый объект и колонку с реальностью; (3) найти утверждения об одном объекте, противоречащие друг другу; (4) отметить незаявленные допущения.
3. **Выход:** находки с указанием файла, строки и цитаты — как в этом документе. Без цитаты находка непроверяема и будет проигнорирована.
4. **Отсечка ложных срабатываний человеком.** Валидатор, чьи находки не фильтруются, за две недели обучает команду игнорировать себя — ровно как понедельничная ложная тревога по свежести.
5. **У валидатора свой золотой набор.** Иначе некому валидировать валидатора: подсовываем документ с известными двадцатью дефектами и смотрим, сколько он нашёл. Этот документ и есть готовый набор — двадцать размеченных находок с ответами.

Что я бы поставил в CI в первую неделю. Порядок — по отношению пользы к трудозатратам, а не по полноте.

1. Выполнение всех примеров кода из документации на эталонных данных. Дешевле всего, находит самый опасный класс — «скопировал из документа и получил неверное число».
2. Сверка имён из документации с `INFORMATION_SCHEMA`. Ловит A2, A4, B1, B4, C4 одним тестом.
3. Снимок DDL и сверка с журналом изменений — уже собрано, работает.
4. LLM-ревью на противоречия — раз в неделю по расписанию, а не на каждый коммит: это самый дорогой и самый шумный детектор.

Что я предлагаю сделать с самими приложениями

Не править. Приложения выданы как условие задания, и правка условия под свою реализацию — подмена. Правильный порядок такой:

1. **Шесть критичных находок** (A1, A2, A3, B1, B5, C2, D2, E2) вынести в тикеты на владельца документации с цитатами — это работа первой недели, а не предмет спора.
2. **Отрицательный COR% в Appendix C и путаницу знаков в t-статистике** исправить в первую очередь: они дают неверное число молча.
3. **Календарь праздников** сверить с официальным источником CNBV и перевести на загрузку вместо ручного перечня.
4. **Заметки интервью** пометить как машинную расшифровку — одна строка в шапке файла, а стоимость ошибки высокая, если их прочтёт агент.

Все цитаты проверяемы: файл и номер строки указаны для каждой находки. Три находки класса C получены прогоном документированных запросов по песочнице `snowflake-sandbox/`; остальные — вычиткой.